

# Maya: límite actual de conocimiento y camino a un modelo propio

Oct 6, 2026 · @Manny

Para Eduardo y Juan. Hoy Maya no es un modelo propio: es Claude leyendo, en cada mensaje, hasta 60.000 caracteres de entrenamiento de Planea. Ese límite se puede ampliar, y cuando Planea quiera aprender de sus usuarios activos, el paso siguiente es un modelo propio.

## Hoy

Todo lo que ustedes le enseñan a Maya queda guardado en una tabla propia de Planea, `pplanea_kb_docs`, en la base de datos del servidor. No queda en el modelo.

- **Qué se guarda:** los documentos de "Conocimiento de Maya", las correcciones y respuestas aprobadas de "Entrenar a Maya", y las instrucciones escritas en el chat de entrenamiento.
- **Con qué datos:** quién lo agregó, la fecha y la versión. Editar guarda una versión nueva; desactivar oculta sin borrar.
- **Cómo lo usa Maya:** en cada mensaje, Claude (hoy el modelo Haiku 4.5) recibe todo el entrenamiento activo junto con la pregunta del usuario. Por eso una regla nueva funciona de inmediato, sin reentrenar nada.
- **El límite:** el total de entrenamiento activo no puede pasar de **60.000 caracteres** (unas 25–30 páginas, alrededor de 15.000 tokens). Si una carga lo supera, la pantalla la rechaza y dice por qué.

Esos 60.000 caracteres son de Planea. Si mañana se cambia de modelo, el conocimiento se queda.

## Qué significa el límite

El límite es de cuánto **sabe** Maya, no de cuántas personas la usan. Para la etapa actual de Planea alcanza.

- **No depende del número de usuarios.** Con 10 o con 10.000 usuarios, cada mensaje lleva el mismo entrenamiento. Más usuarios significan más mensajes, no menos espacio.

- **Sí depende del costo.** Cada mensaje paga la lectura de todo el entrenamiento activo. Duplicar el entrenamiento casi duplica el costo de cada respuesta y la hace un poco más lenta.
- **Se puede ampliar sin programar.** Es un valor ( `PLANEA_KB_MAX_CHARS` ) que se cambia en el servidor y aplica de inmediato. Ampliarlo más allá de 60.000 caracteres es un upgrade facturable.
- **El techo es el de Claude.** Claude puede leer unos 200.000 tokens a la vez, cerca de 800.000 caracteres contando la conversación. Un techo práctico y seguro está entre 400.000 y 500.000 caracteres.

## Cómo crece

Maya puede crecer en tres etapas. Cada una se activa cuando la anterior se queda corta, no antes.

| Etapas                      | Qué cambia                                                                                                                             | Cuándo pasar                                                                                | Lo que cuesta                                                                                    |
|-----------------------------|----------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|
| 1. Ampliar el límite (hoy)  | Se sube <code>PLANEA_KB_MAX_CHARS</code> hasta unos 400.000–500.000 caracteres                                                         | Cuando el entrenamiento se acerque a 60.000                                                 | Upgrade facturable. Cada mensaje cuesta más en proporción al entrenamiento                       |
| 2. Buscar solo lo relevante | En cada pregunta, Maya busca en el conocimiento las partes que aplican y lee solo esas. El conocimiento deja de tener un tope práctico | Cuando el conocimiento pase del techo de Claude, o el costo por mensaje pese                | Desarrollo nuevo. Baja el costo por mensaje, porque ya no se lee todo                            |
| 3. Modelo propio (mini LLM) | Se entrena un modelo más pequeño con las conversaciones y correcciones de Planea. El conocimiento queda dentro del modelo              | Cuando Planea quiera aprender de sus usuarios activos y tenga volumen de datos para hacerlo | Entrenamiento, servidores con GPU y mantenimiento. Crecen los tokens, el espacio y el costo fijo |

Las etapas se suman: un modelo propio también puede seguir leyendo las reglas del equipo, para corregirlo sin reentrenarlo cada vez.

## Aprender de los usuarios activos

Hoy Maya aprende solo de lo que el equipo de Planea le enseña. Las conversaciones de los usuarios no se guardan, así que todavía no hay datos de usuarios con qué entrenar.

Antes de entrenar un modelo con datos de usuarios hace falta:

1. **Autorización del usuario.** La Ley 1581 de 2012 (habeas data) exige autorización previa para usar datos personales con este fin. Hay que actualizar la política de privacidad y pedir el consentimiento.
2. **Guardar las conversaciones** de quienes lo autoricen. Es un cambio de código y de almacenamiento.
3. **Quitar datos personales y montos** antes de entrenar. Un modelo puede repetir lo que aprendió.
4. **Revisión humana.** Solo se entrena con respuestas que el equipo marcó como correctas, para que el modelo no aprenda errores.
5. **Volumen suficiente.** Un modelo propio necesita miles de ejemplos revisados para superar a Claude con entrenamiento leído.

## Decisión hoy y próximos pasos

Hoy no hace falta un modelo propio. Lo recomendado es seguir en la etapa 1 y medir.

- ☐ Seguir entrenando a Maya en "Entrenar a Maya" y "Conocimiento de Maya".
- ☐ Avisar cuando el entrenamiento se acerque a 60.000 caracteres, para cotizar la ampliación del límite como upgrade facturable.
- ☐ Decidir si Planea quiere aprender de sus usuarios. Si es así, empezar por el consentimiento y la política de privacidad.
- ☐ Revisar el costo por mensaje antes de pasar a la etapa 2 o 3. Hoy no hay cifras medidas de esas etapas; se cotizan cuando llegue el momento.